

# Занятие 4

## Линейные модели классификации.

Елена Кантонистова

[elena.kantonistova@yandex.ru](mailto:elena.kantonistova@yandex.ru)

ВШЭ, 2020

# ОБУЧЕНИЕ ЛИНЕЙНОЙ РЕГРЕССИИ (НАПОМИНАНИЕ)

Обучающая выборка:

$x_1, x_2, \dots, x_n$  - объекты,  $y_1, y_2, \dots, y_n$  - ответы (**любые числа**).

- Модель линейной регрессии:

$$a(x, w) = \sum_{j=1}^n w_j x_j$$


- Метод обучения – метод наименьших квадратов (**минимизируем разность между предсказанием и правильным ответом**):

$$Q(w) = \sum_{i=1}^n (a(x_i, w) - y_i)^2 \rightarrow \min_w$$

# БИНАРНАЯ КЛАССИФИКАЦИЯ

Обучающая выборка:


$x_1, x_2, \dots, x_n$  - объекты,  $y_1, y_2, \dots, y_n$  - ответы (**+1 или -1**).



# БИНАРНАЯ КЛАССИФИКАЦИЯ

Обучающая выборка:

$x_1, x_2, \dots, x_n$  - объекты,  $y_1, y_2, \dots, y_n$  - ответы (**+1 или -1**).



Как выглядит модель линейного классификатора:  $a(x, w) = ?$

# БИНАРНАЯ КЛАССИФИКАЦИЯ

Модель линейного классификатора:

$$a(x, w) = \textit{sign}\left(\sum_{j=1}^n w_j x_j\right)$$

# БИНАРНАЯ КЛАССИФИКАЦИЯ

Модель линейного классификатора:

$$a(x, w) = \textit{sign}\left(\sum_{j=1}^n w_j x_j\right)$$

- если  $\sum_{j=1}^n w_j x_j > 0$ , то  $\textit{sign}(\sum_{j=1}^n w_j x_j) = +1$ , то есть объект отнесён к положительному классу
- если  $\sum_{j=1}^n w_j x_j < 0$ , то  $\textit{sign}(\sum_{j=1}^n w_j x_j) = -1$ , то есть объект отнесён к отрицательному классу

# БИНАРНАЯ КЛАССИФИКАЦИЯ

Модель линейного классификатора:

$$a(x, w) = \textit{sign}\left(\sum_{j=1}^n w_j x_j\right)$$

- если  $\sum_{j=1}^n w_j x_j > 0$ , то  $\textit{sign}(\sum_{j=1}^n w_j x_j) = +1$ , то есть объект отнесён к положительному классу
- если  $\sum_{j=1}^n w_j x_j < 0$ , то  $\textit{sign}(\sum_{j=1}^n w_j x_j) = -1$ , то есть объект отнесён к отрицательному классу
- значит,  $\sum_{j=1}^n w_j x_j = 0$  – уравнение разделяющей границы между классами. Это уравнение плоскости (или прямой в двумерном случае), поэтому классификатор является линейным.

# БИНАРНАЯ КЛАССИФИКАЦИЯ


Модель линейного классификатора:

$$a(x, w) = \text{sign}\left(\sum_{j=1}^n w_j x_j\right)$$

Уравнение

$$\sum_{j=1}^n w_j x_j = 0$$

– уравнение плоскости  
(или прямой).





# ОБУЧЕНИЕ КЛАССИФИКАТОРА

*Как обучить линейный классификатор?*

# ОБУЧЕНИЕ КЛАССИФИКАТОРА

- Обучение - минимизация доли ошибок классификатора:

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l [a(x_i) \neq y_i] \rightarrow \min,$$

где  $[a(x_i) \neq y_i] = 1$ , если предсказание на объекте неверное, то есть  $a(x_i) \neq y_i$ , и 0 иначе.

# ОБУЧЕНИЕ КЛАССИФИКАТОРА

- Обучение - минимизация доли ошибок классификатора:

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l [a(x_i) \neq y_i] \rightarrow \min (*),$$

где  $[a(x_i) \neq y_i] = 1$ , если предсказание на объекте неверное, то есть  $a(x_i) \neq y_i$ , и 0 иначе.

- Обозначим  $M_i = y_i \cdot (w, x_i)$  - **отступ** на  $i$ -м объекте.

# ОБУЧЕНИЕ КЛАССИФИКАТОРА

- Обучение - минимизация доли ошибок классификатора:

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l [a(x_i) \neq y_i] \rightarrow \min (*),$$

где  $[a(x_i) \neq y_i] = 1$ , если предсказание на объекте неверное, то есть  $a(x_i) \neq y_i$ , и 0 иначе.

- Обозначим  $M_i = y_i \cdot (w, x_i)$  - **отступ** на  $i$ -м объекте.

Можно показать, что решение задачи (\*) эквивалентно решению задачи

$$Q(a, X) = \frac{1}{l} \sum_{i=1}^l [M_i < 0] \rightarrow \min$$

# ОТСТУП (MARGIN)

Знак отступа  $M = y \cdot (w, x)$  говорит о корректности классификации на объекте:

# ОТСТУП (MARGIN)

Знак отступа  $M = y \cdot (w, x)$  говорит о корректности классификации на объекте:

Случаи неверной классификации (предсказание не совпадает с правильным ответом):

- Если  $(w, x) > 0$  (то есть объект отнесён к классу  $+1$ ), а  $y = -1$ , то  $M = y \cdot (w, x) < 0$ .

# ОТСТУП (MARGIN)

Знак отступа  $M = y \cdot (w, x)$  говорит о корректности классификации на объекте:

Случаи неверной классификации (предсказание не совпадает с правильным ответом):

- Если  $(w, x) > 0$  (то есть объект отнесён к классу  $+1$ ), а  $y = -1$ , то  $M = y \cdot (w, x) < 0$ .
- Аналогично, если  $(w, x) < 0$ , а  $y = +1$ , то  $M = y \cdot (w, x) < 0$ .

# ОТСТУП (MARGIN)

Знак отступа  $M = y \cdot (w, x)$  говорит о корректности классификации на объекте:

Случаи неверной классификации (предсказание не совпадает с правильным ответом):

- Если  $(w, x) > 0$  (то есть объект отнесён к классу  $+1$ ), а  $y = -1$ , то  $M = y \cdot (w, x) < 0$ .
- Аналогично, если  $(w, x) < 0$ , а  $y = +1$ , то  $M = y \cdot (w, x) < 0$ .


Случаи верной классификации:

- Если  $(w, x) > 0$  и  $y = +1$  или  $(w, x) < 0$  и  $y = -1$  получаем  $M = y \cdot (w, x) > 0$ .



# ОТСТУП (MARGIN)

Ранжирование объектов по возрастанию отступа:



# ВЕРХНИЕ ОЦЕНКИ ЭМПИРИЧЕСКОГО РИСКА

- $Q(a, X) = \frac{1}{l} \sum_{i=1}^l [\mathbf{M}_i < \mathbf{0}]$  – разрывная функция потерь, поэтому её минимум неудобно находить методом градиентного спуска (нельзя взять производную).

# ВЕРХНИЕ ОЦЕНКИ ЭМПИРИЧЕСКОГО РИСКА


- $Q(a, X) = \frac{1}{l} \sum_{i=1}^l [\mathbf{M}_i < \mathbf{0}]$  – разрывная функция потерь, поэтому её минимум неудобно находить методом градиентного спуска (нельзя взять производную).
- Поэтому для решения задачи классификации *вместо разрывной функции  $[M < 0]$  берут непрерывные или гладкие функции потерь  $L(M)$ .*

# ФУНКЦИИ ПОТЕРЬ

*Минимизируя различные функции потерь, получаем разные результаты. Поэтому разным функциям потерь соответствуют различные классификаторы.*

- $L(M) = \log(1 + e^{-M})$  – логистическая функция потерь
- $V(M) = (1 - M)_+ = \max(0, 1 - M)$  – кусочно-линейная функция потерь (метод опорных векторов)
- $H(M) = (-M)_+ = \max(0, -M)$  – кусочно-линейная функция потерь (персептрон)
- $E(M) = e^{-M}$  - экспоненциальная функция потерь
- $S(M) = \frac{2}{1+e^{-M}}$  - сигмоидная функция потерь
- $[M < 0]$  – пороговая функция потерь

# ФУНКЦИИ ПОТЕРЬ



$M$

# ОПТИМИЗАЦИЯ ФУНКЦИОНАЛА ПОТЕРЬ

- Нахождение минимума функции потерь  $Q$  происходит с помощью метода градиентного спуска:

$$\mathbf{w}^{(k)} = \mathbf{w}^{(k-1)} - \eta \cdot \nabla Q(\mathbf{w}^{(k-1)})$$

The background features a series of concentric circles in a light gray color, centered on the page. In the four corners, there are stylized circuit board traces in a light blue color, with small circles at the end of the lines, resembling electronic components or data paths.

# МЕТРИКИ КАЧЕСТВА

# МЕТРИКИ КАЧЕСТВА КЛАССИФИКАЦИИ

- Accuracy – доля правильных ответов:

$$accuracy(a, X) = \frac{1}{l} \sum_{i=1}^l [a(x_i) = y_i]$$



# МЕТРИКИ КАЧЕСТВА КЛАССИФИКАЦИИ

- Accuracy – доля правильных ответов:

$$accuracy(a, X) = \frac{1}{l} \sum_{i=1}^l [a(x_i) = y_i]$$

*Недостаток: при сильно несбалансированной выборке не отражает качество работы алгоритма*

# МАТРИЦА ОШИБОК

Матрица ошибок (confusion matrix):

		Actual Value	
		positives	negatives
Predicted Value	positives	<b>TP</b> True Positive	<b>FP</b> False Positive
	negatives	<b>FN</b> False Negative	<b>TN</b> True Negative

# МЕТРИКИ КАЧЕСТВА КЛАССИФИКАЦИИ: PRECISION, RECALL

- **Precision (точность):**

$$\textit{Precision}(a, X) = \frac{TP}{TP + FP}$$

Показывает, насколько можно доверять классификатору при  $a(x) = +1$ .

# PRECISION: ПРИМЕР

Модель  $a_1(x)$ :

$$\text{precision}(a_1, X) = 0.8$$

Модель  $a_2(x)$ :

$$\text{precision}(a_2, X) = 0.96$$

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	80	20
$a(x) = -1$ Не получили кредит	20	80

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	48	2
$a(x) = -1$ Не получили кредит	52	98

# МЕТРИКИ КАЧЕСТВА КЛАССИФИКАЦИИ: PRECISION, RECALL

- **Precision** (точность):

$$\textit{Precision}(a, X) = \frac{TP}{TP + FP}$$

Показывает, насколько можно доверять классификатору при  $a(x) = +1$ .

- **Recall** (полнота):

$$\textit{Recall}(a, X) = \frac{TP}{TP + FN}$$

Показывает, как много объектов положительного класса находит классификатор.

# RECALL: ПРИМЕР

Модель  $a_1(x)$ :

$$\text{recall}(a_1, X) = 0.8$$


	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	80	20
$a(x) = -1$ Не получили кредит	20	80

Модель  $a_2(x)$ :

$$\text{recall}(a_2, X) = 0.48$$

	$y = 1$ Могут вернуть	$y = -1$ Не могут вернуть
$a(x) = 1$ Получили кредит	48	2
$a(x) = -1$ Не получили кредит	52	98

# ТОЧНОСТЬ И ПОЛНОТА




$$\text{Precision} = \frac{\text{true positives}}{\text{true positives} + \text{false positives}}$$

$$\text{Recall} = \frac{\text{true positives}}{\text{true positives} + \text{false negatives}}$$

# F-МЕРА

F-мера – это метрика качества, учитывающая и точность, и полноту

$$F(a, X) = \frac{2 \cdot \textit{Precision} \cdot \textit{Recall}}{\textit{Precision} + \textit{Recall}}$$





# РЕГУЛИРУЕМ ТОЧНОСТЬ И ПОЛНОТУ

Пусть  $p(x)$  - уверенность классификатора в том, что объект  $x$  относится к классу  $+1$ ,  $p(x) \in [0; 1]$ .

Обычно если  $p(x) > 0.5$ , то мы относим объект к положительному классу, а иначе – к отрицательному.

# РЕГУЛИРУЕМ ТОЧНОСТЬ И ПОЛНОТУ

Пусть  $p(x)$  - уверенность классификатора в том, что объект  $x$  относится к классу  $+1$ ,  $p(x) \in [0; 1]$ .

Обычно если  $p(x) > 0.5$ , то мы относим объект к положительному классу, а иначе – к отрицательному.

Можно изменять этот порог, то есть вместо 0.5 брать другое число из отрезка  $[0; 1]$ .

# РЕГУЛИРУЕМ ТОЧНОСТЬ И ПОЛНОТУ

Пусть  $p(x)$  - уверенность классификатора в том, что объект  $x$  относится к классу  $+1$ ,  $p(x) \in [0; 1]$ .

Обычно если  $p(x) > 0.5$ , то мы относим объект к положительному классу, а иначе – к отрицательному.

Можно изменять этот порог, то есть вместо 0.5 брать другое число из отрезка  $[0; 1]$ .

**Путем изменения порога  $t$  можно регулировать точность и полноту:**

- Например, если  $t = 0$ , то мы все объекты относим к положительному классу, то есть полнота  $= 1$ , а точность маленькая.
- При увеличении  $t$  полнота уменьшается (могут появиться объекты положительного класса, которые мы не нашли), а точность возрастет (появляются объекты положительного класса).

# ИНТЕГРАЛЬНАЯ МЕТРИКА: ROC-AUC

Хотим измерить качество всего семейства классификаторов независимо от выбранного порога.

Для этого будем использовать метрику AUC

**AUC** – *Area Under ROC Curve* (площадь под ROC-кривой)

# ROC-КРИВАЯ


Для каждого значения порога  $t$  вычислим:

- False Positive Rate - долю неверно принятых объектов
- True Positive Rate -долю верно принятых объектов

Кривая, состоящая из точек с координатами (FPR, TPR) для всех возможных порогов – это и есть ROC-кривая.

# ROC-КРИВАЯ


Кривая, состоящая из точек с координатами (FPR, TPR) для всех возможных порогов – это и есть ROC-кривая.



# ROC-КРИВАЯ. AUC.

**AUC (Area Under Curve)** – площадь под ROC-кривой.  
 $AUC \in [0; 1]$ .

- $AUC = 1$  –  
идеальная классификация
- $AUC = 0.5$  –  
случайная классификация



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по убыванию предсказаний:  
(0.7, 0.4, 0.2, 0.1, 0.05)

**1 шаг:**  $t = 0.7$ , то есть

$$a(x) = [b(x) > 0.7]$$

$$TPR = \frac{TP}{TP+FN}$$

$$FPR = \frac{FP}{FP+TN}$$

# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по убыванию предсказаний:  
(0.7, 0.4, 0.2, 0.1, 0.05)

**1 шаг:  $t = 0.7$ , то есть**

$$TPR = \frac{TP}{TP+FN}$$

$$FPR = \frac{FP}{FP+TN}$$

$$a(x) = [b(x) > 0.7]$$

$$TPR = \frac{0}{0+3} = 0, \quad FPR = \frac{0}{0+2} = 0.$$

# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Пусть есть выборка из 5 объектов и следующие предсказания классификатора оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1


- Упорядочим объекты по убыванию предсказаний:  
(0.7, 0.4, 0.2, 0.1, 0.05)

**1 шаг:**  $t = 0.7$ , то есть

$$a(x) = [b(x) > 0.7]$$

$$TPR = \frac{0}{0+3} = 0,$$

$$FPR = \frac{0}{0+2} = 0.$$



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по

убыванию предсказаний:


(0.7, 0.4, 0.2, 0.1, 0.05)

**2 шаг:**  $t = 0.4$ , то есть

$$a(x) = [b(x) > 0.4]$$

$$TPR = \frac{1}{1+2} = \frac{1}{3},$$

$$FPR = \frac{0}{0+2} = 0.$$



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по

убыванию предсказаний:


(0.7, 0.4, 0.2, 0.1, 0.05)

**3 шаг:**  $t = 0.2$ , то есть

$$a(x) = [b(x) > 0.2]$$

$$TPR = \frac{2}{2+1} = \frac{2}{3},$$

$$FPR = \frac{0}{0+2} = 0.$$



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по

убыванию предсказаний:


(0.7, 0.4, 0.2, 0.1, 0.05)

**4 шаг:**  $t = 0.1$ , то есть

$$a(x) = [b(x) > 0.1]$$

$$TPR = \frac{2}{2+1} = \frac{2}{3},$$

$$FPR = \frac{1}{1+1} = \frac{1}{2}.$$



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:


$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по убыванию предсказаний:  
(0.7, 0.4, 0.2, 0.1, 0.05)

**5 шаг:**  $t = 0.05$ , то есть  
 $a(x) = [b(x) > 0.05]$

$$TPR = \frac{2}{2+1} = \frac{2}{3},$$

$$FPR = \frac{2}{2+0} = 1.$$



# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

- Оценки принадлежности к классу +1:

$b(x)$	0.2	0.4	0.1	0.7	0.05
$y$	-1	+1	-1	+1	+1

- Упорядочим объекты по

убыванию предсказаний:


(0.7, 0.4, 0.2, 0.1, 0.05)

**5 шаг:**  $t = 0$ , то есть

$$a(x) = [b(x) > 0]$$

$$TPR = \frac{3}{3+0} = 1,$$

$$FPR = \frac{2}{2+0} = 1.$$





# ПРИМЕР ПОСТРОЕНИЯ ROC-КРИВОЙ

$$AUC = 2/3$$

